Identificação de padrões e anomalias em reclamações de telecomunicações no Nordeste brasileiro usando aprendizado não supervisionado

***Sayonara Cristina de Oliveira Magalhães*[1]**
***Emelyn Clementino Freire*[1,2]**
***Arthur Phelipe de Oliveira Queiroz*[2]**
***Marcelo Jorge Oliveira de Albuquerque Melo*[2]**

[1] *Programa de Pós-Graduação em Engenharia Elétrica e de Computação (PPgEEC), Centro de Tecnologia, Universidade Federal do Rio Grande do Norte (UFRN), Natal, RN, Brasil*
[2] *Departamento de Engenharia de Computação e Automação (DCA), UFRN, Natal, RN, Brasil*
<sayonara.magalhaes.068@ufrn.edu.br>,
<emelyn.freire.116@ufrn.edu.br>,
<arthur.queiroz.115@ufrn.edu.br>,
<marcelo.melo.703@ufrn.edu.br>

Resumo

Reclamações de consumidores de telecomunicações dos nove estados do Nordeste brasileiro, registradas entre janeiro de 2020 e agosto de 2026, foram agregadas por estado, município, mês e serviço, o que resultou em 212.626 registros e 2.003.561 solicitações. Para cada um dos 1.794 municípios, foram calculados 11 atributos de volume, variabilidade, serviços e tipos de problema. Os atributos padronizados foram submetidos ao K-Means e, após redução por análise de componentes principais (PCA), ao DBSCAN, com avaliação pelo Silhouette Score e pelo índice de Davies-Bouldin. O K-Means separou os municípios em dois grupos, de 698 e 1.096 municípios, com separação fraca (Silhouette de 0,1870). O DBSCAN (`eps` = 1,0; `min_samples` = 10) formou um grupo principal de 1.282 municípios e dois grupos menores, de 17 e 6, e rotulou 489 municípios (27,26%) como ruído, entre eles grandes capitais e 282 municípios com menos de 100 solicitações. Para ordenar prioridades, calculou-se a taxa de reclamações por 100 mil habitantes nos 12 meses mais recentes e sua variação. Os 20 municípios de maior taxa estão fora do grupo principal do DBSCAN, e Salvador lidera, com taxa 4,0 vezes a regional. Os resultados indicam onde investigar e não equivalem a uma medida de qualidade do serviço.

Palavras-chave: aprendizado não supervisionado; K-Means; DBSCAN; telecomunicações; detecção de anomalias.

Abstract

Consumer complaints about telecommunications services in the nine states of the Brazilian Northeast, recorded from January 2020 to August 2026, were aggregated by state, municipality, month and service, yielding 212,626 records and 2,003,561 requests. For each of the 1,794 municipalities, we computed 11 attributes describing volume, variability, services and problem types. The standardized attributes were clustered with K-Means and, after principal component analysis (PCA), with DBSCAN; both were assessed with the Silhouette Score and the Davies-Bouldin index. K-Means split the municipalities into two groups of 698 and 1,096, with weak separation (Silhouette of 0.1870). DBSCAN (`eps` = 1.0; `min_samples` = 10) formed a main cluster of 1,282 municipalities and two smaller ones, of 17 and 6, and labelled 489 municipalities (27.26%) as noise, among

them large capitals and 282 municipalities with fewer than 100 requests. To rank priorities, we computed the complaint rate per 100,000 inhabitants over the most recent 12 months and its change. The 20 municipalities with the highest rates lie outside the main DBSCAN cluster, and Salvador ranks first, at 4.0 times the regional rate. The results indicate where to investigate and are not a measure of service quality.

Keywords: unsupervised learning; K-Means; DBSCAN; telecommunications; anomaly detection.

1 Introdução

Os serviços de telecomunicações sustentam a comunicação, o acesso à informação e boa parte da atividade econômica. As reclamações registradas pelos consumidores constituem um registro contínuo da qualidade percebida desses serviços e podem indicar localidades que merecem investigação. Somente em 2020, a plataforma Anatel Consumidor recebeu 2,96 milhões de reclamações no país (FREITAS; ANDREÃO, 2021).

Esse volume inviabiliza o exame manual, e os registros não trazem rótulo que indique quais municípios apresentam comportamento fora do esperado. O aprendizado não supervisionado é adequado a esse cenário, pois agrupa observações semelhantes e destaca as que se afastam do comportamento predominante sem depender de classes definidas previamente (JAIN, 2010; CHANDOLA; BANERJEE; KUMAR, 2009).

O objetivo deste trabalho é identificar perfis municipais e comportamentos atípicos nas reclamações de telecomunicações dos nove estados do Nordeste brasileiro. Para isso, descreve-se um fluxo reproduzível que parte da agregação mensal dos registros, constrói atributos por município e compara dois algoritmos de natureza distinta: o K-Means, baseado em centroides, e o DBSCAN, baseado em densidade e capaz de rotular observações como ruído.

2 Trabalhos relacionados

Entre os métodos de agrupamento, o K-Means é um dos mais difundidos. Ele particiona as observações em k grupos de modo a minimizar a variância interna de cada grupo (MACQUEEN, 1967). Jain (2010) revisa cinco décadas de uso do algoritmo e aponta suas restrições conhecidas: o número de grupos precisa ser informado, o resultado depende da inicialização e grupos de tamanho ou formato muito desiguais tendem a ser mal representados.

O DBSCAN define grupos como regiões de alta densidade, delimitadas por um raio de vizinhança (`eps`) e por um número mínimo de vizinhos (`min_samples`), e rotula como ruído os pontos que não pertencem a nenhuma dessas regiões (ESTER et al., 1996). Schubert et al. (2017) mostram que o desempenho e o resultado do algoritmo dependem fortemente da escolha desses dois parâmetros.

Na taxonomia de Chandola, Banerjee e Kumar (2009), uma família de técnicas de detecção de anomalias baseadas em agrupamento assume que observações normais pertencem a algum grupo e anomalias, a nenhum. O rótulo de ruído do DBSCAN corresponde a essa definição. Para avaliar partições sem rótulos de referência, são usuais o Silhouette Score (ROUSSEEUW, 1987) e o índice de Davies-Bouldin (DAVIES; BOULDIN, 1979).

No domínio das reclamações de telecomunicações, os estudos localizados tratam a reclamação individual como unidade de análise. Freitas e Andreão (2021) propõem uma rotina de limpeza do texto de respostas a reclamações da plataforma Anatel Consumidor, voltada à construção de classificadores supervisionados. Cardoso (2024) aplica o K-Means a 794 reclamações sobre chamadas não solicitadas. Ubeda et al. (2025) classificam a avaliação atribuída pelo consumidor à resposta da operadora em mais de 900 mil reclamações do Consumidor.gov.br. Oliveira et al. (2025) descrevem 2.061.022 reclamações de telecomunicações da mesma plataforma, registradas de 2015 a 2024, com estatística descritiva e teste qui-quadrado. Assis et al. (2017) relacionam reclamações coletadas no Twitter, localizadas por cidade, ao número de estações rádio base da operadora. Fora do contexto brasileiro, Faed et al. (2016) combinam PCA e análise envoltória de dados no tratamento de reclamações de clientes. Este trabalho muda a unidade de análise para o município: cada um é descrito por atributos calculados sobre todo o período e agrupado com o K-Means e o DBSCAN.

3 Metodologia

3.1 Dados e preparação mensal

Os dados provêm do Anatel Consumidor, sistema da Agência Nacional de Telecomunicações (Anatel) destinado ao registro de reclamações de consumidores de serviços de telecomunicações, e são disponibilizados publicamente pela agência (AGÊNCIA NACIONAL DE TELECOMUNICAÇÕES, 2026b). Cada registro informa o mês de referência, a unidade da federação, o município (nome e código), o serviço, a descrição do problema e a quantidade de solicitações.

Os arquivos obtidos foram consolidados em uma única base, que cobre o período de janeiro de 2020 a agosto de 2026. Foram mantidos os registros dos nove estados da região Nordeste (Alagoas, Bahia, Ceará, Maranhão, Paraíba, Pernambuco, Piauí, Rio Grande do Norte e Sergipe).

Os registros foram agregados por estado, município, mês e serviço, o que produziu 212.626 linhas. Nove municípios apareciam com duas grafias do nome e foram unificados pelo código do IBGE, de modo que a base reúne 1.794 municípios. Os serviços presentes são telefonia móvel pré-paga (SMP_Pré) e pós-paga (SMP_Pós), banda larga fixa (SCM), telefonia fixa (STFC), TV por assinatura (SeAC) e uma categoria Outros, não detalhada na base. Após a agregação, verificaram-se colunas, duplicidades, cobertura de períodos e estados, valores nulos e valores negativos.

O campo de problema é textual. A partir dele, após conversão para minúsculas, três indicadores foram criados por busca de expressões: lentidão ("lentidão" ou "velocidade reduzida"), queda de conexão ("queda de conexão", "linha muda" ou "sem sinal") e interrupção do serviço ("interrupção do serviço" ou "sem conexão"). Cada indicador soma as solicitações dos registros cuja descrição contém alguma das expressões. Uma mesma descrição pode satisfazer mais de um padrão textual; por isso, os indicadores são analisados separadamente e não formam categorias mutuamente exclusivas.

3.2 Atributos municipais e padronização

Cada município foi descrito por 11 atributos: o logaritmo do total de solicitações no período, na forma $\log(1 + x)$; o coeficiente de variação das solicitações entre os registros de mês e serviço do município; as taxas de lentidão, queda e interrupção, dadas pela razão entre as ocorrências de cada indicador e o total de solicitações do município; e a participação de cada um dos seis serviços no total do município. A transformação logarítmica reduz a influência dos municípios de maior volume. Em municípios com um único registro, o coeficiente de variação foi fixado em zero.

Como os atributos têm escalas diferentes e tanto o K-Means quanto o DBSCAN dependem de distâncias, todas as variáveis foram padronizadas para média zero e desvio-padrão unitário.

3.3 Redução de dimensionalidade

A análise de componentes principais (PCA) projeta os dados em direções ortogonais de máxima variância (JOLLIFFE; CADIMA, 2016). Foram retidos cinco componentes, que explicam 71,67% da variância total (25,82%, 13,27%, 12,00%, 11,18% e 9,40%, na ordem). Esse espaço reduzido foi a entrada do DBSCAN, cuja noção de densidade se degrada à medida que a dimensionalidade cresce. Uma segunda projeção, com dois componentes (39,10% da variância), foi usada apenas para visualização (Figura 2).

3.4 K-Means

O K-Means foi aplicado diretamente aos 11 atributos padronizados, sem PCA, para k de 2 a 8 com inicialização k-means++, 20 reinicializações e semente fixa (42). Selecionou-se o valor de k com maior Silhouette Score.

3.5 DBSCAN

O DBSCAN foi avaliado em uma grade com `eps` $\in \{0{,}4; 0{,}6; 0{,}8; 1{,}0; 1{,}2; 1{,}5; 2{,}0\}$ e `min_samples` $\in \{5; 10\}$, num total de 14 combinações. Selecionou-se a de maior Silhouette Score entre as que produziram ao menos dois grupos e no máximo 30% de ruído. Para o DBSCAN, o Silhouette e o Davies-Bouldin foram calculados apenas sobre os municípios atribuídos a algum grupo. Os pontos de ruído não formam um grupo, mas o conjunto dos municípios que não pertencem a nenhum; tratá-los como um grupo adicional reuniria observações sem semelhança entre si e distorceria a métrica. Nesse caso, a silhueta média desses municípios seria de $-0{,}263$, e a do conjunto cairia para 0,1334. Por isso, a qualidade dos grupos e a fração de ruído são relatadas separadamente. Os municípios com rótulo -1 foram tratados como observações de comportamento atípico em relação aos grupos encontrados. O rótulo descreve apenas a posição do município no espaço de atributos: ele não mede gravidade nem qualidade do serviço.

3.6 Métricas de avaliação

Os agrupamentos foram avaliados por duas métricas que dispensam rótulos de referência. O Silhouette Score (ROUSSEEUW, 1987) compara, para cada observação, a distância média aos membros do próprio grupo com a distância média ao grupo vizinho mais próximo; sua média varia de -1 a 1, e valores maiores indicam grupos mais coesos e separados. O índice de Davies-Bouldin (DAVIES; BOULDIN, 1979) relaciona a dispersão interna dos grupos à distância entre seus centroides, e valores menores indicam melhor separação. As análises foram implementadas em Python com a biblioteca scikit-learn (PEDREGOSA et al., 2011).

3.7 Taxas por habitante e priorização

Os grupos descrevem perfis, mas não ordenam os municípios. Para indicar onde concentrar a investigação, calculou-se a taxa de reclamações por 100 mil habitantes nos 12 meses mais recentes da base (setembro de 2025 a agosto de 2026) e sua variação em relação aos 12 meses anteriores. A população municipal foi recuperada do indicador de densidade de TV por assinatura publicado pela Anatel, pela razão entre acessos e densidade (AGÊNCIA NACIONAL DE TELECOMUNICAÇÕES, 2026a); os valores de 2022 são compatíveis com os do Censo Demográfico. Para evitar taxas instáveis, a ordenação considera apenas os 592 municípios com 20 mil habitantes ou mais. Na banda larga fixa e na telefonia móvel, que somam cerca de 80% das solicitações, calculou-se também a taxa por mil acessos: as solicitações do serviço em 12 meses divididas pela média mensal de acessos do município no mesmo período (AGÊNCIA NACIONAL DE TELECOMUNICAÇÕES, 2026a). Os acessos móveis estavam disponíveis até junho de 2026, e a média considera os meses disponíveis.

4 Resultados

4.1 Análise exploratória

A base agregada soma 2.003.561 solicitações entre janeiro de 2020 e agosto de 2026. A Bahia concentra 733.882 delas (36,63%), seguida por Pernambuco (18,60%) e Ceará (15,90%); os outros seis estados têm participações entre 3,32% e 6,43%. Entre os serviços, o SMP_Pós é o mais frequente, com 682.663 solicitações (34,07%), seguido por SMP_Pré (23,72%), SCM (21,73%), STFC (10,22%), SeAC (5,38%) e Outros (4,87%).

A concentração repete-se entre os municípios. Salvador, Fortaleza e Recife lideram o volume, e as nove capitais estão entre os dez municípios com mais solicitações, ao lado de Feira de Santana.

O volume mensal diminuiu ao longo da maior parte do período. O máximo ocorreu em maio de 2020, com 44.281 solicitações, e o mínimo em novembro de 2024, com 16.583. A média mensal caiu de 38.691 solicitações em 2020 para 18.233 em 2024 e subiu para 21.525 nos oito meses observados de 2026 (Figura 1).

Os três indicadores textuais somam 226.226 ocorrências: 107.940 de interrupção (47,71%), 84.335 de queda de conexão (37,28%) e 33.951 de lentidão (15,01%). Esses percentuais têm como base a soma das ocorrências, que equivale a, no máximo, 11,29% do total de solicitações, já que uma descrição pode ser contada em mais de um indicador. A banda larga fixa (SCM) concentra 73,80% das ocorrências de lentidão e 53,70% das de interrupção, enquanto a telefonia fixa (STFC) responde por 48,78% das de queda.

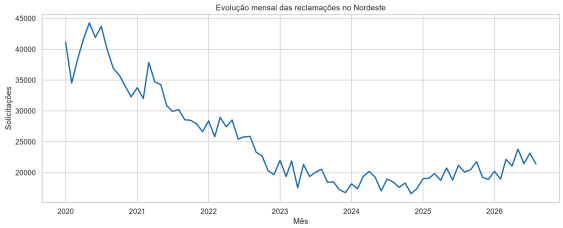


Figura 1: *Evolução mensal do total de solicitações no Nordeste (jan. 2020 a ago. 2026).*

4.2 Comparação dos modelos

No K-Means, o maior Silhouette foi obtido com $k = 2$ (0,1870), seguido por $k = 4$ (0,1797), enquanto o Davies-Bouldin diminui com o número de grupos. Em todas as configurações, o Silhouette é baixo, o que indica grupos pouco separados (Tabela 1).

No DBSCAN, a fração de ruído variou de 2,29% a 100% entre as 14 combinações, e oito delas produziram no máximo um grupo. Entre as que respeitam o limite de 30% de ruído, `eps` = 1,0 e `min_samples` = 10 obteve o maior Silhouette (0,2907), com três grupos e um conjunto de ruído.

Tabela 1: *Métricas de avaliação por configuração (selecionadas em negrito). No K-Means, o parâmetro é k; no DBSCAN, `eps` e `min_samples` (MS), apenas nas configurações com dois ou mais grupos. Silh.: Silhouette; DB: Davies-Bouldin.*

Modelo	Parâmetro	Grupos	Ruído (%)	Silh.	DB
K-Means	$\boldsymbol{k = 2}$	**2**	—	**0,1870**	**2,0104**
K-Means	$k = 3$	3	—	0,1778	2,2374
K-Means	$k = 4$	4	—	0,1797	1,8006
K-Means	$k = 5$	5	—	0,1562	1,6836
K-Means	$k = 6$	6	—	0,1293	1,7330
K-Means	$k = 7$	7	—	0,1283	1,6741
K-Means	$k = 8$	8	—	0,1310	1,6023
DBSCAN	0,4; MS 5	8	97,44	0,4654	0,7698
DBSCAN	0,6; MS 5	11	61,37	−0,1077	0,8245
DBSCAN	0,8; MS 5	6	35,01	0,0743	0,7067
DBSCAN	1,0; MS 5	3	19,12	0,2661	0,6463
DBSCAN	**1,0; MS 10**	**3**	**27,26**	**0,2907**	**0,7967**
DBSCAN	1,2; MS 5	3	11,87	0,2899	0,6956

A leitura da Tabela 1 exige cautela. O K-Means atribui todos os 1.794 municípios a algum grupo e opera sobre os atributos padronizados. O DBSCAN opera sobre cinco componentes principais e deixa 489 municípios fora dos grupos, e esses municípios não entram no cálculo de suas métricas. As métricas,

portanto, descrevem partições de conjuntos e espaços diferentes e não ordenam diretamente os dois algoritmos.

4.3 Perfis dos grupos do K-Means

O Grupo A reúne 698 municípios (38,91%), com média de 2.695,61 solicitações por município. O Grupo B reúne 1.096 municípios (61,09%), com média de 111,34. As taxas médias de lentidão, queda e interrupção do Grupo A são de 1,9 a 2,2 vezes as do Grupo B, e seu coeficiente de variação médio também é maior (Tabela 2).

A composição dos serviços difere entre os grupos. No Grupo B, o SMP_Pré responde, em média, por 51,22% das solicitações do município; no Grupo A, por 34,96%. O Grupo A tem participações médias maiores de SMP_Pós, SCM e STFC (8,43% contra 3,17%).

Na projeção sobre os dois primeiros componentes principais (Figura 2, à esquerda), os dois grupos ocupam regiões contíguas, separadas ao longo do primeiro componente, sem lacuna visível entre elas.

4.4 Grupos e municípios atípicos no DBSCAN

O DBSCAN identificou um grupo principal com 1.282 municípios (71,46%), dois grupos menores, com 17 e 6 municípios, e 489 municípios (27,26%) rotulados como ruído (Figura 2, à direita). O grupo 1 tem a maior média de solicitações (23.596,35) e a maior participação média de banda larga fixa: 26,30%, contra 5,33% no grupo principal (Tabela 2). Ele reúne cinco capitais (João Pessoa, Aracaju, Maceió, Natal e Teresina) e outros doze municípios: Campina Grande, Vitória da Conquista, Caruaru, Itabuna, Parnamirim, Juazeiro do Norte, Caucaia, Mossoró, Nossa Senhora do Socorro, São José de Ribamar, Barreiras e Crato. Seus totais somam 401.138 solicitações (20,02% do total). O grupo 2 (Parnaíba, Timon, Aquiraz, Quixadá, Cascavel e Ceará-Mirim) tem volume bem menor, de 1.129 a 3.534 solicitações por município, e também se distingue pela banda larga fixa (22,52%). Os 23 municípios dos dois grupos pertencem ao Grupo A do K-Means.

Na Figura 2, o grupo principal concentra-se na região central da projeção, e os grupos 1 e 2 aparecem em valores elevados do primeiro componente. Os pontos de ruído predominam na periferia, mas também se sobrepõem ao grupo principal. Essa sobreposição é esperada, pois o DBSCAN foi ajustado em cinco componentes e a figura exibe apenas dois, que retêm 39,10% da variância.

Os municípios rotulados como ruído não foram tratados como problemáticos. O conjunto é heterogêneo e reúne os dois extremos de porte. De um lado, a mediana é de 68 solicitações, e 282 dos 489 municípios (57,67%) registraram menos de 100 no período. De outro, estão nele Salvador, Fortaleza, Recife, São Luís e Feira de Santana, e o conjunto soma 1.210.580 solicitações (60,42% do total). Em relação ao K-Means, 262 desses municípios pertencem ao Grupo A e 227 ao Grupo B.

4.5 Taxas por habitante e prioridades

Nos 12 meses mais recentes, o Nordeste registrou 252.564 solicitações, ou 462,2 por 100 mil habitantes, 11,0% acima dos 12 meses anteriores (416,3). A Bahia tem a maior taxa (592,0) e o Maranhão, a menor (241,1); as maiores altas ocorreram no Piauí (25,3%) e no Rio Grande do Norte (24,6%). Entre os serviços, cresceram o SMP_Pós (18,2%), o SCM (9,4%) e a categoria Outros (64,8%), enquanto recuaram o STFC (−24,6%), o SeAC (−20,0%) e o SMP_Pré (−3,6%).

Entre os 592 municípios com 20 mil habitantes ou mais, a taxa mediana é de 176,8, e nove superam o dobro da taxa regional. A Tabela 3 lista os dez primeiros. A divisão pela população não desfaz a concentração nos grandes centros: Salvador permanece em primeiro lugar, com taxa 4,0 vezes a regional, seis dos dez municípios são capitais, e outros dois, Lauro de Freitas e Olinda, são vizinhos de capitais. A correlação de postos entre população e taxa (0,45) é, ainda assim, menor que entre população e volume (0,79).

Dois casos ilustram o uso conjunto de taxa e variação. Cocal (PI), com 28 mil habitantes, é o único município de pequeno porte na lista: suas solicitações mais que quadruplicaram, e 69,8% delas referem-se à TV por assinatura, o que sugere um problema localizado em um único serviço. Natal combina taxa elevada (2,2 vezes a regional) com a maior alta entre as capitais (27,5%).

Na banda larga fixa, os acessos permitem um denominador mais adequado. A região registrou 6,44 solicitações por mil acessos, praticamente o mesmo valor do período anterior (6,41): o aumento de 9,4% nas solicitações do serviço acompanha o crescimento de 8,8% da base de acessos. A ordem dos municípios pouco se altera (Tabela 4). Salvador mantém a primeira posição, com taxa 4,3 vezes a regional, embora tenha menos acessos por 100 habitantes (21,7) do que João Pessoa (35,8) ou Natal (34,2); sua posição, portanto, não decorre de maior difusão do serviço. Quatro municípios da região metropolitana do

Tabela 2: *Perfil médio dos grupos do K-Means e do DBSCAN (taxas e participações em % das solicitações do município). CV: coeficiente de variação.*

Grupo	Municípios	Média de solic.	CV	Lentidão	Queda	Interrupção	SMP_Pré	SMP_Pós	SCM
K-Means A	698	2.695,61	0,69	1,56	5,41	5,63	34,96	31,81	9,32
K-Means B	1.096	111,34	0,49	0,82	2,43	3,03	51,22	21,23	4,88
DBSCAN principal	1.282	295,61	0,58	0,81	2,95	3,50	47,85	25,54	5,33
DBSCAN grupo 1	17	23.596,35	0,87	2,07	2,86	4,17	22,37	35,20	26,30
DBSCAN grupo 2	6	2.145,67	0,77	2,38	3,11	5,03	32,12	24,72	22,52
DBSCAN ruído	489	2.475,62	0,53	1,83	5,29	5,44	38,09	24,51	9,09

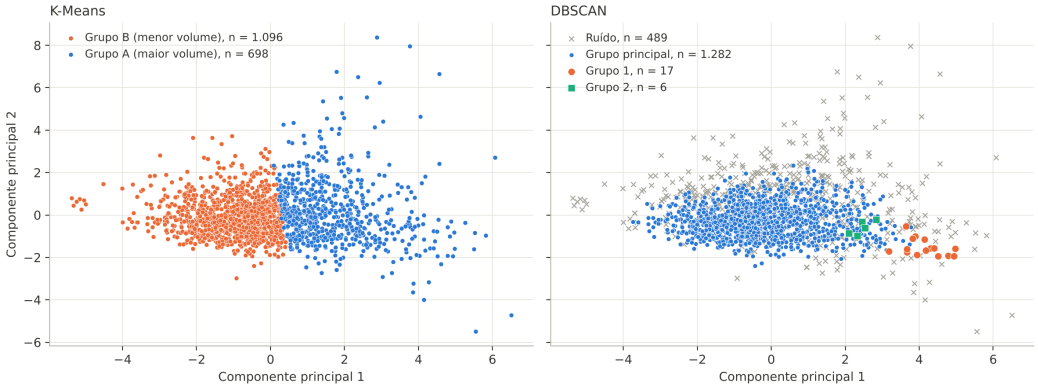


Figura 2: *Municípios no plano dos dois primeiros componentes principais, com os grupos do K-Means (esquerda) e do DBSCAN (direita).*

Recife estão entre os sete primeiros. As maiores altas entre as capitais ocorreram em Natal (54,1%) e Teresina (43,7%).

Na telefonia móvel, o quadro é outro. A taxa regional foi de 2,54 solicitações por mil acessos, 7,4% acima do período anterior: as solicitações cresceram 9,2% e a base, 1,7%, de modo que a alta não se explica pelo crescimento da base. O pós-pago concentra o problema, com 3,45 solicitações por mil acessos, o dobro do pré-pago (1,73), e alta de 7,6%. Entre os municípios, a taxa é menos associada ao porte (correlação de postos de 0,24 com a população). Salvador tem a segunda maior taxa (6,24, ou 2,5 vezes a regional), e seis dos dez primeiros municípios são baianos; seis dos dez, porém, têm menos de cem solicitações no período e devem ser lidos com reserva.

Os rótulos do DBSCAN acompanham a ordenação por habitante. Nenhum dos 20 municípios de maior taxa por habitante pertence ao grupo principal: 11 estão no ruído e 9 no grupo 1. Entre os municípios com 20 mil habitantes ou mais, a taxa mediana é de 165,4 no grupo principal, 264,4 no ruído, 247,8 no grupo 2 e 629,9 no grupo 1.

5 Discussão

A partição do K-Means é dominada pelo volume: a média de solicitações do Grupo A é cerca de 24 vezes a do Grupo B.

A solução com dois grupos é simples de comunicar, mas o Silhouette de 0,1870 indica separação fraca, coerente com a Figura 2, em que os grupos formam uma nuvem contínua. Os perfis municipais parecem variar de modo gradual, e a partição funciona mais como um corte ao longo de um gradiente de volume do que como identificação de grupos naturais.

O DBSCAN complementa essa leitura por não forçar todo município a pertencer a um grupo. Seu Silhouette (0,2907) deve ser lido com reserva, pois, calculado sem os pontos de ruído, refere-se a uma partição com um grupo de 1.282 municípios e dois grupos pequenos. A fração de 27,26% de ruído é elevada para ser lida como conjunto de anomalias em sentido estrito e depende dos parâmetros: entre as configurações com dois ou mais grupos, variou de 11,87% a 97,44%, o que está de acordo com a sensibilidade descrita por Schubert et al. (2017).

A composição do ruído reforça a interpretação adotada. Ele reúne capitais como Salvador, Fortaleza e Recife e, em maior número, municípios com poucas dezenas de solicitações. O que esses casos têm em comum é a distância em relação ao perfil mais frequente, e não um nível de qualidade de serviço. Os grupos 1 e 2, por sua vez, sugerem um perfil comum a parte das capitais e a municípios urbanos de porte intermediário, marcado pela maior partici-

Tabela 3: *Dez municípios com maior taxa de reclamações por 100 mil habitantes entre set. 2025 e ago. 2026 (municípios com 20 mil habitantes ou mais). Variação em relação aos 12 meses anteriores; serviço com maior número de solicitações no período e sua participação.*

	Município (UF)	População	Solicitações	Taxa	Variação (%)	Serviço principal	DBSCAN
1	Salvador (BA)	2.418.005	45.006	1.861,3	+0,5	SMP_Pós (37,9%)	ruído
2	Lauro de Freitas (BA)	203.334	3.125	1.536,9	−2,2	SMP_Pós (40,7%)	ruído
3	Recife (PE)	1.488.920	20.379	1.368,7	+10,1	SMP_Pós (37,1%)	ruído
4	Cocal (PI)	28.212	354	1.254,8	+359,7	SeAC (69,8%)	ruído
5	Aracaju (SE)	602.757	7.408	1.229,0	+17,0	SMP_Pós (39,9%)	grupo 1
6	João Pessoa (PB)	833.932	9.619	1.153,5	+19,1	SMP_Pós (39,3%)	grupo 1
7	Fortaleza (CE)	2.428.678	27.687	1.140,0	+13,8	SCM (38,4%)	ruído
8	Natal (RN)	751.300	7.521	1.001,1	+27,5	SMP_Pós (36,5%)	grupo 1
9	Olinda (PE)	349.976	3.372	963,5	+12,8	SMP_Pós (34,5%)	ruído
10	Feira de Santana (BA)	616.279	5.378	872,7	+5,0	SMP_Pós (48,3%)	ruído

Tabela 4: *Municípios com maior taxa de solicitações de banda larga fixa por mil acessos entre set. 2025 e ago. 2026 (20 mil habitantes ou mais). Acessos: média mensal, em milhares.*

Município (UF)	Acessos	Taxa	Variação (%)
Salvador (BA)	525,2	27,9	−6,3
Olinda (PE)	44,9	24,4	+5,6
Recife (PE)	286,3	23,4	+6,9
Lauro de Freitas (BA)	46,8	22,0	−38,7
Fortaleza (CE)	718,3	14,8	+15,9
Paulista (PE)	40,9	12,5	+6,6
Jaboatão dos Guararapes (PE)	72,5	12,4	+3,7
Eunápolis (BA)	16,8	10,8	+10,9

pação da banda larga fixa.

As taxas por habitante dão a esses rótulos uma leitura prática. O agrupamento, feito sem informação de população, separou do grupo principal os municípios que depois se mostraram de maior taxa, de modo que o ruído e os grupos menores delimitam onde procurar. A ordenação por taxa e variação indica por onde começar: municípios de taxa alta e estável, como Salvador, apontam problemas persistentes, e os de alta recente, como Cocal e Natal, apontam mudanças a examinar. Essa leitura requer cautela, pois a taxa por habitante também reflete a difusão dos serviços e a propensão a recorrer à Anatel, maiores nos grandes centros. Na banda larga fixa, a taxa por acessos manteve a ordem, o que sugere que a difusão não explica o resultado nesse serviço. Na telefonia móvel, a concentração nas capitais diminui, embora Salvador e Lauro de Freitas permaneçam entre os primeiros.

6 Limitações

Os tipos de problema foram identificados por palavras-chave, de modo que descrições equivalentes redigidas com outros termos podem não ter sido captadas. Os acessos foram usados como denominador na banda larga fixa e na telefonia móvel; a taxa geral e a dos demais serviços usam a população, o que impede separar a incidência de problemas da penetração dos serviços. A população foi obtida de forma indireta, a partir de um indicador da Anatel. A categoria Outros depende de documentação da fonte para ser interpretada.

No agrupamento, a agregação de todo o período em um único vetor por município não distingue mudanças de comportamento ao longo dos anos. O número de municípios rotulados como ruído depende diretamente de `eps` e `min_samples`, e a estabilidade dos grupos frente a variações desses parâmetros e da inicialização do K-Means não foi avaliada. Os limites de 30% de ruído, na seleção do DBSCAN, e de 20 mil habitantes, na ordenação, são arbitrários. Por fim, os dois algoritmos foram aplicados a espaços distintos, o que restringe a comparação entre suas métricas.

7 Conclusão

A agregação mensal das reclamações e a construção de atributos por município permitiram descrever 1.794 municípios do Nordeste com dois algoritmos não supervisionados. O K-Means separou os municípios em dois grupos, diferenciados sobretudo pelo volume de solicitações, com separação fraca (Silhouette de 0,1870). O DBSCAN identificou um grupo principal, dois grupos menores, de 17 e 6 municípios, e 489 municípios fora do padrão dominante.

A taxa por 100 mil habitantes e sua variação recente acrescentaram uma ordem de prioridade. Os 20 municípios de maior taxa estão fora do grupo principal do DBSCAN, e a lista é encabeçada por Salvador, Lauro de Freitas e Recife; Cocal destaca-se pela alta abrupta, concentrada na TV por assinatura. Na banda larga fixa, a taxa por mil acessos mantém Salvador na primeira posição; na telefonia

móvel, a taxa regional subiu 7,4%, puxada pelo pós-pago. Os resultados são preliminares: indicam onde investigar e não permitem afirmar, por si, onde o serviço é pior. Como trabalhos futuros, propõe-se estender o cálculo por acessos à telefonia fixa e à TV por assinatura, usar as categorias de problema da própria Anatel, avaliar a estabilidade dos grupos e construir um painel de acompanhamento mensal.

Referências

AGÊNCIA NACIONAL DE TELECOMUNICAÇÕES. *Painéis de dados: acessos*. Brasília: Anatel, 2026. Dados brutos de banda larga fixa, telefonia móvel e TV por assinatura, em arquivos ZIP. Disponível em: <https://informacoes.anatel.gov.br/paineis/acessos>. Acesso em: 9 out. 2026.

AGÊNCIA NACIONAL DE TELECOMUNICAÇÕES. *Painéis de dados: reclamações*. Brasília: Anatel, 2026. Dados brutos em arquivo ZIP. Disponível em: <https://informacoes.anatel.gov.br/paineis/consumidor/reclamacoes>. Acesso em: 9 set. 2026.

ASSIS, E. K. et al. Information system for the improvement of telecommunication service quality. In: SIMPÓSIO BRASILEIRO DE SISTEMAS DE INFORMAÇÃO (SBSI), 13., 2017, Lavras. *Anais [...]*. Porto Alegre: Sociedade Brasileira de Computação, 2017. p. 452–455.

CARDOSO, I. L. *Modelo integrado para melhoria da qualidade em serviços de telecomunicações*. 2024. Projeto de Graduação (Engenharia de Produção) – Universidade de Brasília, Brasília, 2024. Disponível em: <https://bdm.unb.br/handle/10483/41311>. Acesso em: 6 out. 2026.

CHANDOLA, V.; BANERJEE, A.; KUMAR, V. Anomaly detection: a survey. *ACM Computing Surveys*, v. 41, n. 3, p. 1–58, 2009.

DAVIES, D. L.; BOULDIN, D. W. A cluster separation measure. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, PAMI-1, n. 2, p. 224–227, 1979.

ESTER, M. et al. A density-based algorithm for discovering clusters in large spatial databases with noise. In: INTERNATIONAL CONFERENCE ON KNOWLEDGE DISCOVERY AND DATA MINING, 2., 1996, Portland. *Proceedings [...]*. Menlo Park: AAAI Press, 1996. p. 226–231.

FAED, A. et al. Intelligent customer complaint handling utilising principal component and data envelopment analysis (PDA). *Applied Soft Computing*, v. 47, p. 614–630, 2016.

FREITAS, M. S.; ANDREÃO, R. V. Automatização do processamento do texto bruto oriundo de um serviço de atendimento de reclamações. In: ESCOLA REGIONAL DE INFORMÁTICA DO RIO DE JANEIRO (ERI-RJ), 4., 2021, Online. *Anais [...]*. Porto Alegre: Sociedade Brasileira de Computação, 2021. p. 72–79.

JAIN, A. K. Data clustering: 50 years beyond K-means. *Pattern Recognition Letters*, v. 31, n. 8, p. 651–666, 2010.

JOLLIFFE, I. T.; CADIMA, J. Principal component analysis: a review and recent developments. *Philosophical Transactions of the Royal Society A*, v. 374, n. 2065, p. 20150202, 2016.

MACQUEEN, J. Some methods for classification and analysis of multivariate observations. In: BERKELEY SYMPOSIUM ON MATHEMATICAL STATISTICS AND PROBABILITY, 5., 1967, Berkeley. *Proceedings [...]*. Berkeley: University of California Press, 1967. v. 1, p. 281–297.

OLIVEIRA, L. D. M. et al. A voz do consumidor no setor de telecomunicações: um estudo das reclamações no consumidor.gov.br. *Revista de Gestão e Secretariado*, v. 16, n. 2, p. 1–29, 2025.

PEDREGOSA, F. et al. Scikit-learn: machine learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825–2830, 2011.

ROUSSEEUW, P. J. Silhouettes: a graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, v. 20, p. 53–65, 1987.

SCHUBERT, E. et al. DBSCAN revisited, revisited: why and how you should (still) use DBSCAN. *ACM Transactions on Database Systems*, v. 42, n. 3, p. 1–21, 2017.

UBEDA, G. N. et al. Avaliação automática da qualidade das respostas para reclamações no setor de telefonia no Brasil. In: SIMPÓSIO BRASILEIRO DE SISTEMAS DE INFORMAÇÃO (SBSI), 21., 2025, Recife. *Anais estendidos [...]*. Porto Alegre: Sociedade Brasileira de Computação, 2025. p. 147–151.