Arquitetura *Edge–Cloud* para Monitoramento Inteligente de Veículos Conectados com Auditabilidade via *Blockchain*

Miguel Euripedes [1], Morsinaldo Medeiros [1], Thais Medeiros [1], Hilton Machado [1], Erick Justino [1], Alice Freire [1], Marianne Silva[2], Carlos M. D. Viegas[1], Ivanovitch Silva[1]

[1] Dep. Eng. de Computação e Automação (DCA), UFRN
<miguel.amaral.111@ufrn.edu.br>,
<morsinaldo.medeiros.075@ufrn.edu.br>,
<thais.araujo.707@ufrn.edu.br>,
<hilton.machado.088@ufrn.edu.br>,
<erick.justino.701@ufrn.edu.br>,
<alice.victorino.061@ufrn.edu.br>, <carlos.viegas@ufrn.br>,
<ivanovitch.silva@ufrn.br>
[2] Curso Sistemas de Informação - Campus Arapiraca, UFAL
<marianne.silva@penedo.ufal.br>

Resumo

O monitoramento de sistemas veiculares conectados requer a integração entre aquisição de sinais, processamento inteligente e infraestrutura computacional capaz de lidar com fluxos contínuos de dados. Neste trabalho, propõe-se e avalia-se uma arquitetura modular para monitoramento veicular que integra aquisição de dados veiculares via OBD-II, processamento na borda (*edge*), métodos de inteligência artificial, *soft-sensors*, serviços em nuvem e registro distribuído em *blockchain*. Como estudo de caso, a arquitetura foi aplicada à análise do comportamento de condução e à estimativa de emissões de CO_2. Nos ensaios de infraestrutura, foram processados 627.515 registros a uma taxa média de 9,86 registros/s, com latência predominantemente entre 0 e 2 s no trecho instrumentado. Em condições reais de operação, os dados veiculares foram integrados às saídas dos modelos TEDA e MMCloud e às estimativas de CO_2. A integração com uma rede permissionada Hyperledger Besu também foi avaliada, com registro e posterior recuperação das informações consolidadas de uma viagem e tempo médio de aproximadamente 4,40 s entre o envio da requisição e a confirmação da transação. Os resultados fornecem evidências da viabilidade funcional da arquitetura nas condições avaliadas, integrando monitoramento, análise inteligente, infraestrutura de dados e registro distribuído e auditável.

Abstract

Monitoring connected vehicular systems requires integrating signal acquisition, intelligent processing, and infrastructure capable of handling continuous data streams. This work proposes and evaluates a modular architecture combining OBD-II data acquisition, edge processing, artificial intelligence methods, soft sensors, cloud services, and blockchain-based record-keeping. As a case study, the architecture was applied to driving behavior analysis and CO_2 emission estimation. Infrastructure experiments processed 627,515 records at an average rate of 9.86 records/s, with latency predominantly between 0 and 2 s in the instrumented segment. Under real-world operating conditions, vehicular data were integrated with TEDA and MMCloud outputs and CO_2 estimates. Integration with a permissioned Hyperledger Besu network was evaluated by recording and subsequently retrieving consolidated trip information, with an average time of approximately 4.40 s between request submission and transaction confirmation. The results support the architecture's functional feasibility under the evaluated conditions.

1 Introdução

O monitoramento de sistemas físicos depende da transformação de dados de sensores em informações sobre suas condições de operação (ZENDRON et al., 2025). No domínio veicular, parâmetros como velocidade, rotação do motor, carga do motor e posição do acelerador podem ser obtidos por meio de PIDs (*Parameter IDs*) disponibilizados pela interface *On-Board Diagnostics* (OBD-II) do veículo, constituindo uma fonte de dados para aplicações de monitoramento e supervisão (MICHAILIDIS; PANAGIOTOPOULOU; PAPADAKIS, 2025).

A combinação de computação em borda com serviços em nuvem e inteligência artificial amplia as possibilidades de processamento desses dados (KAGAWADE et al., 2026). Enquanto a borda permite executar análises próximas à fonte, a nuvem possibilita persistir e disponibilizar registros para diferentes aplicações (NILSSON et al., 2025). Métodos de inteligência artificial e *soft-sensors* complementam esse fluxo ao identificar padrões operacionais e inferir variáveis não diretamente medidas (LU; WANG, 2026). Entretanto, a integração dessas tecnologias exige coordenar aquisição, processamento, comunicação, armazenamento e disponibilização dos dados (ZHANG et al., 2026).

No contexto veicular, essa integração permite combinar a análise do comportamento de condução com a estimativa de grandezas como emissões de CO_2 a partir dos parâmetros operacionais (RYKAŁA; GRZELAK; BORUCKA, 2024). Além do processamento e da disponibilização dessas informações, aplicações que dependem de registros verificáveis requerem mecanismos capazes de preservar sua integridade e auditabilidade. Nesse contexto, tecnologias *blockchain* podem complementar a infraestrutura de monitoramento por meio do registro distribuído e auditável das informações produzidas pela plataforma (TYAGI; TIWARI; NAITHANI, 2024).

Diante desse cenário, este trabalho propõe e avalia uma arquitetura modular que integra aquisição de dados via interface OBD-II, processamento na borda, análise inteligente, infraestrutura em nuvem e registro distribuído em *blockchain*. Um estudo de caso é utilizado para avaliar a aquisição e disponibilidade dos dados, a execução dos métodos de análise comportamental, a estimativa de CO_2, o desempenho da infraestrutura e a integração com uma rede permissionada Hyperledger Besu (BESU, 2026).

As principais contribuições são: (i) a especificação de uma arquitetura modular que integra computação na borda, nuvem e *blockchain* para o monitoramento de dados veiculares; (ii) a integração de métodos de inteligência artificial e *soft-sensors* ao fluxo de processamento; e (iii) a implementação e avaliação dos componentes da arquitetura, incluindo aquisição de dados via OBD-II, infraestrutura de dados e registro distribuído das informações consolidadas das viagens.

O restante do artigo está organizado em cinco seções: a Seção 2 apresenta os trabalhos relacionados; a Seção 3 descreve a arquitetura proposta; a Seção 4 apresenta o estudo de caso; a Seção 5 apresenta e discute os resultados; e a Seção 6 apresenta as conclusões.

2 Trabalhos Relacionados

Estudos recentes têm explorado dados veiculares, inteligência artificial e processamento distribuído para monitoramento de veículos conectados. Michailidis, Panagiotopoulou e Papadakis (2025) revisam aplicações de aprendizado de máquina com dados OBD-II para análise de consumo, emissões, comportamento e diagnóstico. Andrade et al. (2022) apresentam um *soft-sensor* para estimativa de CO_2 a partir de sinais OBD-II, enquanto Medeiros et al. (2024) combinam *soft-sensors*, TEDA e agrupamento incremental para análise do comportamento do condutor na borda.

No nível arquitetural, Nilsson et al. (2025) apresentam a AutoSPADA para processamento distribuído entre veículos e nuvem, enquanto Ku et al. (2025) propõem o V2X-Car Edge Cloud para gerenciamento de serviços distribuídos em ambientes veiculares.

No monitoramento de emissões, Farrag et al. (2025) combinam sensores de gases, comunicação sem fio, nuvem e aprendizado profundo, enquanto Biswas, Chowdhury e Chandra (2026) empregam sensoriamento, processamento em borda e aprendizado de máquina. Diferentemente dessas abordagens, neste trabalho o CO_2 é estimado a partir de parâmetros OBD-II por meio de um *soft-sensor*, sem sensores dedicados de gases.

A tecnologia *blockchain* também tem sido aplicada à rastreabilidade de emissões. Liu et al. (2024) propõem um mecanismo de autenticação para ambientes de contabilização de emissões veiculares, utilizando *blockchain* para o registro dessas informações, enquanto Lu et al. (2022) apresentam o STRICTs, baseado em Hyperledger Fabric para auditoria e negociação de permissões de emissão.

Deste modo, este trabalho integra elementos tratados separadamente na literatura em uma arquitetura modular que articula aquisição OBD-II, processamento inteligente na borda, infraestrutura em nuvem, supervisão e registro auditável em *blockchain*.

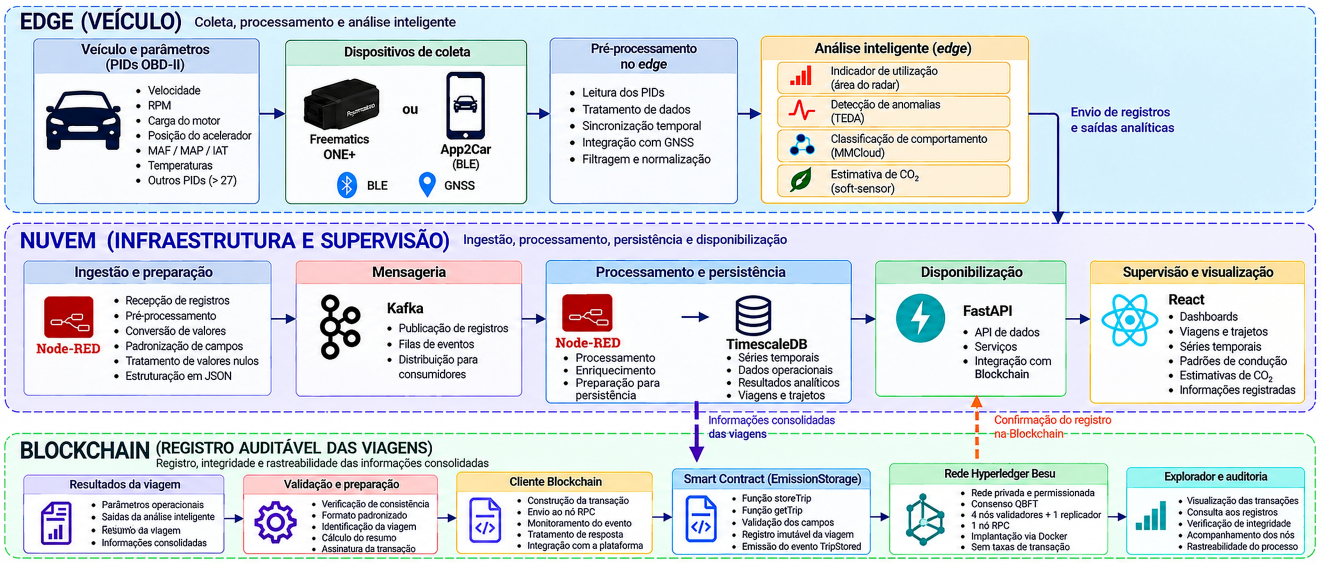


Figura 1: *Visão geral da arquitetura modular proposta.*

A contribuição está na integração e avaliação desse fluxo, incluindo o registro das informações consolidadas das viagens em uma rede permissionada Hyperledger Besu.

3 Arquitetura Proposta

A arquitetura proposta, ilustrada pela Figura 1, organiza o monitoramento veicular em um fluxo modular que integra leitura dos parâmetros veiculares, coleta de dados, processamento inteligente, infraestrutura de dados, supervisão e registro distribuído.

O fluxo inicia-se na borda com a leitura dos parâmetros veiculares, identificados por PIDs (*Parameter IDs*), por meio da interface OBD-II conectada ao veículo. Os dados são coletados por dispositivos de borda e utilizados pelos métodos de análise inteligente para geração de indicadores, detecção de anomalias, classificação do comportamento de condução e estimação de emissões de CO_2. Os registros e as saídas analíticas são então encaminhados à infraestrutura em nuvem, onde são preparados, distribuídos, processados e armazenados como séries temporais. Serviços de acesso e visualização disponibilizam essas informações para aplicações de monitoramento e supervisão. Complementarmente, informações consolidadas podem ser encaminhadas ao módulo *blockchain* para registro verificável e auditável, fornecendo informações rastreáveis que podem subsidiar mecanismos de créditos de carbono.

3.1 Coleta e análise inteligente na borda

A coleta de dados veiculares é realizada por meio da interface OBD-II, abrangendo mais de 27 PIDs disponibilizados pelo veículo. Esses parâmetros fornecem informações sobre diferentes condições de operação, incluindo velocidade, rotação do motor, carga do motor, posição do acelerador, temperaturas e variáveis relacionadas à admissão de ar, entre outras. Para as análises consideradas neste trabalho, são utilizados subconjuntos desses parâmetros de acordo com a informação a ser inferida.

Na análise comportamental, são empregados principalmente velocidade, rotação do motor, carga do motor e posição do acelerador. Para a estimativa de CO_2, utiliza-se o fluxo de massa de ar (MAF), quando disponível, ou parâmetros necessários à sua estimação, como pressão absoluta no coletor de admissão (MAP), temperatura do ar de admissão (IAT) e rotação do motor. Informações de localização obtidas por GNSS (*Global Navigation Satellite System*) complementam os registros e permitem associar os dados operacionais aos trajetos percorridos.

Para isso, a arquitetura admite duas opções de coleta. A primeira utiliza o dispositivo Freematics ONE+, baseado no ESP32 com interface OBD-II e receptor GNSS, que possibilita a aquisição e o processamento local dos sensores (ANDRADE et al., 2022). A segunda utiliza o aplicativo *App2Car*, desenvolvido pelo laboratório Conect2AI, que se comunica com o veículo por meio de um adaptador OBD-II sem fio, baseado na tecnologia *Bluetooth Low Energy* (BLE) e emprega o dispositivo móvel como *gateway*. Ambas as modalidades alimentam a mesma infraestrutura de dados, permitindo desacoplar a fonte de aquisição das etapas posteriores de processamento e armazenamento.

A camada de análise inteligente combina dois fluxos complementares. O primeiro caracteriza padrões

de condução a partir de indicadores derivados dos sensores veiculares. Para isso, os sensores selecionados são normalizados e representados em um gráfico de radar, no qual cada eixo corresponde a uma variável operacional. A área do polígono formado por esses sinais é utilizada para produzir um indicador que sintetiza conjuntamente as condições de utilização do veículo.

Conforme ilustra a Figura 2, o polígono do radar pode ser decomposto em triângulos formados pelo centro da representação e por dois vértices consecutivos.

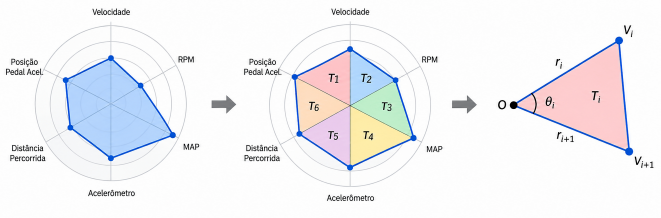


Figura 2: *Decomposição do gráfico de radar para o cálculo da área do indicador de utilização.*

A área total é obtida pela soma das áreas desses triângulos. Considerando n eixos igualmente espaçados e $r_i(t)$ o valor normalizado do sinal associado ao eixo i no instante t, a área do polígono é dada por:

$$A(t) = \frac{1}{2}\sin\left(\frac{2\pi}{n}\right)\sum_{i=1}^{n} r_i(t)r_{i+1}(t), \qquad r_{n+1}(t) = r_1(t) \tag{1}$$

A partir de uma configuração de referência de área B, define-se o indicador normalizado:

$$I(t) = \frac{A(t)}{B} \tag{2}$$

O indicador $I(t)$ sintetiza a magnitude conjunta dos sinais operacionais e alimenta os métodos de análise comportamental. O *framework* TEDA (*Typicality and Eccentricity Data Analytics*) analisa cada nova observação a partir de medidas de tipicidade e excentricidade, que representam, respectivamente, sua similaridade e seu afastamento em relação ao comportamento observado no fluxo de dados (MEDEIROS; SILVA; SILVA, 2025). Essas medidas são atualizadas recursivamente, permitindo sinalizar observações atípicas sem armazenar todo o histórico.

Para caracterizar os padrões de condução, o MMCloud utiliza o indicador de utilização dos recursos do veículo e a carga do motor como entradas de um processo de agrupamento incremental. A cada nova observação, sua distância em relação aos centroides existentes é avaliada e as estatísticas dos grupos são atualizadas, permitindo adaptar os agrupamentos à evolução do fluxo de dados (MEDEIROS; SILVA; SILVA, 2025). Na configuração utilizada, são considerados até três grupos, associados aos perfis *cauteloso*, *normal* e *agressivo* conforme a ordenação das normas de seus centroides.

O segundo fluxo analítico utiliza um *soft-sensor* para estimar as emissões de CO_2 a partir do fluxo de massa de ar admitido pelo motor. Quando o sinal MAF não está disponível, esse fluxo pode ser estimado pelo método *Speed Density*, de acordo com os parâmetros disponíveis no veículo. Seja $\dot{m}_{ar}(t)$ o fluxo de massa de ar, AFR_f a razão mássica ar–combustível, ρ_f a densidade do combustível e γ_f o fator de emissão correspondente. O fluxo estimado de CO_2 é calculado por:

$$\hat{m}_{CO_2}(t) = \frac{\gamma_f}{\rho_f AFR_f}\dot{m}_{ar}(t) \tag{3}$$

A Equação 3 fornece a taxa estimada de emissão em g/s. Para uma viagem, a massa acumulada de CO_2 é obtida pela integração temporal dessa taxa, aproximada no domínio discreto por:

$$\widehat{M}_{CO_2} \approx \sum_{k=1}^{N} \hat{m}_{CO_2}(t_{k-1})\Delta t_k, \qquad \Delta t_k = t_k - t_{k-1} \tag{4}$$

O uso de Δt_k permite considerar eventuais variações nos intervalos de amostragem durante a integração. Os parâmetros AFR_f, ρ_f e γ_f devem ser definidos de acordo com o combustível utilizado. Dessa forma, a camada analítica combina informações diretamente adquiridas do veículo com variáveis inferidas, produzindo indicadores de comportamento e estimativas de emissão que são encaminhados aos demais componentes da arquitetura.

3.2 Infraestrutura de dados e supervisão

Os dados provenientes da borda são encaminhados à infraestrutura de dados, onde fluxos implementados em Node-RED (NODE-RED, 2026) realizam operações de preparação, incluindo conversão de valores, padronização dos nomes dos campos e tratamento de valores nulos. Os registros são estruturados em JSON e publicados no Apache Kafka (APACHE, 2026), que atua como intermediário entre a produção e o consumo das mensagens. Esse desacoplamento permite que aquisição e persistência operem em ritmos distintos, de acordo com a capacidade e a configuração dos serviços.

No estágio seguinte, outro fluxo Node-RED consome as mensagens e prepara as operações de persistência no TimescaleDB. O armazenamento orientado a séries temporais permite preservar a evolução

dos sinais ao longo das viagens e relacioná-los aos resultados produzidos pela camada analítica. Essa organização também possibilita avaliar propriedades da infraestrutura, como taxa de processamento e latência no trecho instrumentado.

A disponibilização dos dados é realizada por uma API desenvolvida com FastAPI, utilizada tanto por aplicações externas quanto pela interface de supervisão. Uma aplicação desenvolvida em React permite consultar viagens, trajetos, séries temporais, padrões de condução e estimativas instantâneas e acumuladas de CO_2. A separação entre persistência, acesso programático e apresentação permite que os mesmos registros sejam utilizados por diferentes aplicações sem acoplá-las diretamente aos mecanismos de aquisição.

3.3 Registro em *blockchain*

Após o processamento dos dados de uma viagem, as informações consolidadas são encaminhadas ao módulo *blockchain*. Um cliente intermediário é responsável por construir, assinar e submeter a transação ao nó RPC (*Remote Procedure Call*) de uma rede permissionada Hyperledger Besu. A rede utiliza o protocolo de consenso QBFT (*Quorum Byzantine Fault Tolerance*) e opera sem taxas de transação (*free gas*).

O registro é realizado pelo contrato inteligente *EmissionStorage*, implementado em linguagem *Solidity*. A função `storeTrip` recebe as informações consolidadas da viagem, verifica a consistência dos campos e a existência prévia do registro e, após a persistência, emite o evento `TripStored`. Os dados registrados podem posteriormente ser recuperados pela função `getTrip`, permitindo verificar a correspondência entre as informações processadas pela plataforma e aquelas persistidas na rede.

A infraestrutura utilizada é composta por quatro nós validadores, um nó replicador e um nó RPC. Dessa forma, o módulo acrescenta ao fluxo da arquitetura um mecanismo de registro distribuído e auditável das informações produzidas a partir dos dados veiculares.

4 Estudo de Caso

A arquitetura proposta foi avaliada por meio de experimentos complementares, realizados em condições reais de operação e em ambiente controlado. A avaliação possui caráter exploratório e descritivo, abrangendo quatro aspectos: aquisição e disponibilidade dos dados, execução das análises inteligentes, desempenho da infraestrutura e integração com o módulo *blockchain*.

4.1 Cenários

A aquisição em cenário real foi realizada por meio do aplicativo *App2Car*, utilizando duas configurações compostas por adaptadores OBD-II e dispositivos móveis. Para a análise apresentada neste trabalho, foi selecionada uma das viagens registradas, contendo parâmetros operacionais do veículo e as saídas dos métodos TEDA e MMCloud. Esse conjunto foi utilizado para avaliar a regularidade temporal da aquisição, a disponibilidade dos parâmetros e a execução integrada dos métodos de análise comportamental.

A avaliação do *soft-sensor* de CO_2 considerou séries obtidas em viagens realizadas com os veículos VW Polo e Mitsubishi Eclipse. Essas séries foram utilizadas para analisar as estimativas instantâneas de emissão e sua acumulação ao longo do tempo.

Complementarmente, o desempenho da infraestrutura foi caracterizado por meio de um ensaio controlado com dados veiculares simulados. O ensaio teve duração aproximada de 17 h e 40 min e produziu 627.515 registros, permitindo avaliar a taxa de processamento, a latência e a utilização de recursos computacionais.

A integração com o módulo *blockchain* foi avaliada em um percurso experimental, no qual os dados adquiridos foram processados pela plataforma e um registro consolidado da viagem foi submetido a uma rede permissionada Hyperledger Besu. Esse experimento foi utilizado para verificar a integração entre o processamento dos dados veiculares e o registro distribuído associado ao mecanismo de créditos de carbono.

4.2 Procedimentos e métricas de avaliação

Na viagem selecionada do *App2Car*, os registros foram organizados temporalmente e examinados quanto à presença dos parâmetros operacionais e das saídas analíticas. A regularidade da aquisição foi caracterizada pelos intervalos entre observações consecutivas, enquanto a disponibilidade foi determinada pela presença das variáveis nos registros analisados.

Para a análise inteligente, foram consideradas as observações sinalizadas pelo TEDA e a distribuição das classificações produzidas pelo MMCloud, relacionando essas saídas temporalmente aos parâmetros operacionais disponíveis. Para o *soft-sensor*, foram analisadas as estimativas instantâneas de CO_2 e a massa acumulada obtida por integração temporal, conforme descrito na Equação 4.

No ensaio de infraestrutura, foram considerados o número de registros processados, a taxa média de

processamento, a utilização de CPU e memória e a latência. A taxa média foi calculada pela razão entre o número de registros e a duração do ensaio. A latência corresponde à diferença entre o instante de envio do registro e sua chegada ao estágio instrumentado de pré-processamento no Node-RED, não representando, portanto, a latência de ponta a ponta da arquitetura.

Por fim, a integração com a *blockchain* foi avaliada a partir das informações consolidadas da viagem, verificando-se o fluxo entre processamento, submissão da transação, execução do contrato inteligente e confirmação do registro na rede permissionada Hyperledger Besu. Foram considerados a emissão do evento `TripStored`, a recuperação posterior dos dados por meio da função `getTrip` e o tempo entre o envio da requisição pela API e a confirmação da transação. Dessa forma, a avaliação caracteriza a integração funcional e a rastreabilidade das informações utilizadas pelo mecanismo de créditos de carbono, não constituindo um ensaio de capacidade máxima da rede.

5 Resultados

Os resultados são apresentados de acordo com os componentes avaliados da arquitetura, o ensaio controlado de infraestrutura, as séries de emissão e o experimento de integração com *blockchain*.

5.1 Aquisição, plataforma e desempenho da infraestrutura

A viagem selecionada resultou em 684 observações analisadas ao longo de aproximadamente 683 s. O intervalo mediano entre observações consecutivas foi de 1,000 s, com valores entre 0,994 e 1,005 s, caracterizando uma cadência de registro próxima de 1 Hz. Velocidade, rotação do motor, carga do motor, área do radar e as saídas TEDA e MMCloud estavam disponíveis nos registros analisados, permitindo relacionar temporalmente os parâmetros operacionais às saídas da camada de análise inteligente.

Os dados processados são disponibilizados pela plataforma de supervisão, que integra informações das viagens, parâmetros veiculares e resultados produzidos pelos módulos analíticos. A Figura 3 apresenta a interface implementada para acompanhamento das informações processadas pela arquitetura.

No ensaio de infraestrutura, foram processados 627.515 registros durante 63.653 s, correspondendo a uma taxa média de 9,86 registros/s. A latência no trecho instrumentado permaneceu predominantemente entre 0 e 2 s, com picos de até 4 s. A utilização de CPU atingiu 11,3% durante o ensaio, enquanto o uso de memória permaneceu em 1,9%. A Tabela 1 destaca os principais resultados quantitativos obtidos nas diferentes etapas da avaliação.

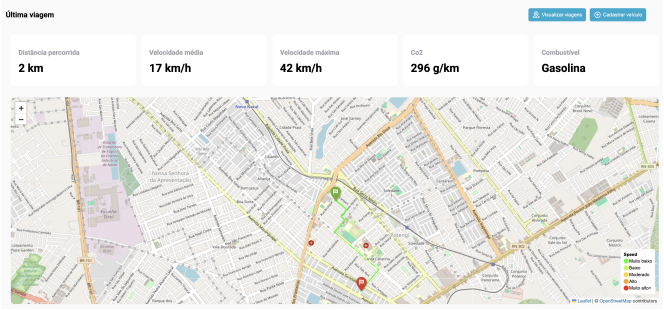


Figura 3: *Interface da plataforma para supervisão dos dados veiculares e dos resultados produzidos pela arquitetura.*

Tabela 1: *Resultados da avaliação da arquitetura.*

Indicador	Resultado obtido
Observações analisadas	684
Intervalo mediano	1,000 s
Faixa dos intervalos	0,994 a 1,005 s
Registros processados	627.515
Taxa média	9,86 registros/s
Latência predominante	0 a 2 s (pico 4 s)
Uso de CPU e Memória RAM	11,3% e 1,9%
TEDA	57 (8,33%)
MMCloud – normal	514 (75,15%)
MMCloud – cauteloso	170 (24,85%)

Os resultados demonstram a disponibilidade conjunta dos parâmetros veiculares e das saídas analíticas, bem como o funcionamento da infraestrutura sob a carga aplicada. O estudo de desempenho, entretanto, caracteriza as condições avaliadas e não determina a capacidade máxima da arquitetura.

5.2 Análise inteligente e estimativa de CO_2

Na viagem analisada, o TEDA sinalizou 57 observações, correspondendo a 8,33% dos registros. Essas ocorrências representam observações identificadas como atípicas em relação ao comportamento do fluxo de dados, permitindo relacioná-las temporalmente às condições operacionais do veículo.

O MMCloud produziu dois códigos de comportamento no conjunto analisado. O comportamento *normal* foi observado em 514 registros (75,15%) e o comportamento *cauteloso* em 170 registros (24,85%). Esses resultados demonstram a execução integrada dos métodos de análise comportamental sobre os dados adquiridos pelo *App2Car*. As proporções observadas não representam, entretanto, uma medida de

acurácia, uma vez que não foi utilizada uma referência independente para as condições de condução.

Além da análise comportamental, o *soft-sensor* foi utilizado para estimar as emissões de CO_2. A Figura 4 apresenta a evolução temporal das emissões acumuladas estimadas para os veículos VW Polo e Mitsubishi Eclipse.

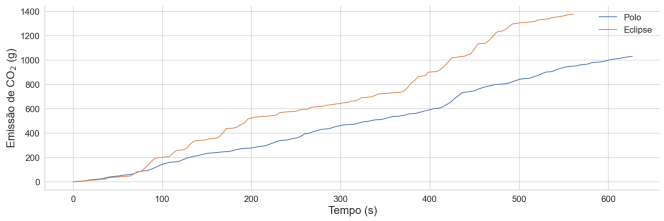


Figura 4: *Evolução temporal das estimativas acumuladas de CO_2 (em gramas) para os veículos VW Polo e Mitsubishi Eclipse.*

As estimativas instantâneas apresentam variações ao longo das viagens, enquanto sua integração temporal resulta no crescimento da massa acumulada de CO_2. Ao final dos respectivos períodos analisados, a emissão acumulada estimada para o veículo Eclipse foi superior à do veículo Polo. Essa diferença, entretanto, não permite comparar diretamente a eficiência dos veículos, pois fatores como duração, distância percorrida e condições de operação também influenciam a emissão acumulada.

Na ausência de uma referência independente de emissão, esses resultados devem ser interpretados como uma demonstração do funcionamento e da integração do *soft-sensor* à arquitetura, e não como uma validação de sua exatidão metrológica.

5.3 Integração com *blockchain*

Na avaliação, o fluxo entre aquisição, processamento e registro distribuído foi executado até a confirmação da transação na rede Hyperledger Besu. Ao término da viagem, as informações consolidadas foram encaminhadas ao cliente *blockchain*, que invocou o contrato inteligente e submeteu a transação à rede. A Figura 5 apresenta a transação correspondente visualizada no explorador da rede. O registro foi confirmado no bloco 1514 e posteriormente recuperado por meio da função `getTrip`.

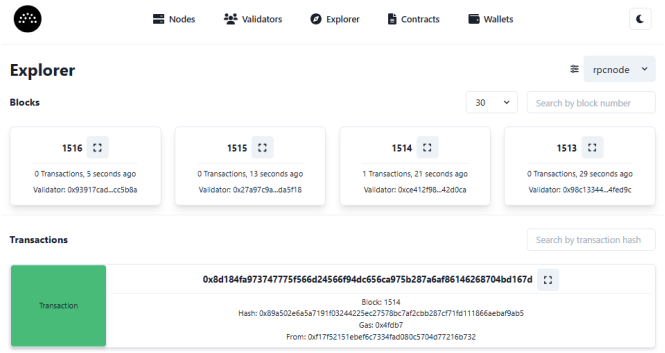


Figura 5: *Transação da viagem registrada no bloco 1514 da rede permissionada Hyperledger Besu.*

O registro recuperado continha as informações consolidadas da viagem, incluindo a estimativa de emissão de 154 g de CO_2. O tempo médio entre o envio da requisição pela API e a confirmação na *blockchain* foi de aproximadamente 4,40 s. O evento `TripStored` foi detectado pelo cliente e os dados recuperados foram validados sem inconsistências.

A confirmação da transação e a posterior recuperação dos dados demonstram a execução do ciclo de escrita, confirmação e consulta das informações da viagem na rede permissionada. Esse mecanismo acrescenta rastreabilidade ao fluxo de dados da arquitetura e fornece uma base auditável para as informações utilizadas pelo mecanismo de créditos de carbono. O experimento caracteriza a integração funcional do módulo nas condições avaliadas, não permitindo inferir a capacidade máxima ou a escalabilidade da rede sob cargas crescentes.

6 Conclusão

Este trabalho apresentou e avaliou uma arquitetura modular para monitoramento e análise inteligente de dados veiculares, integrando coleta via OBD-II, processamento na borda, análise comportamental, estimação de CO_2, infraestrutura em nuvem e registro em *blockchain*. Os resultados demonstraram, nas condições avaliadas, o processamento de 627.515 registros a uma taxa média de 9,86 registros/s, a integração das saídas TEDA e MMCloud aos dados veiculares e a geração de estimativas instantâneas e acumuladas de CO_2. O percurso experimental também demonstrou a integração entre aquisição, processamento e registro consolidado da viagem em uma rede permissionada Hyperledger Besu.

Os resultados fornecem evidências da viabilidade funcional da arquitetura, embora não determinem a capacidade máxima da infraestrutura, a acurácia das análises ou o desempenho da *blockchain* sob cargas

crescentes. Como trabalhos futuros, pretende-se realizar avaliações integradas de ponta a ponta, ampliar os cenários experimentais e avaliar o mecanismo de geração de créditos de carbono.

Agradecimentos

Os autores agradecem à FUNDEP pelo apoio ao desenvolvimento deste trabalho, bem como aos parceiros Volkswagen Truck & Bus, Volkswagen do Brasil, Stellantis e Embeddo pela colaboração no âmbito do projeto.

Referências

ANDRADE, P. et al. A tinyml soft-sensor approach for low-cost detection and monitoring of vehicular emissions. *Sensors*, MDPI, v. 22, n. 10, p. 3838, 2022.

APACHE. *Apache Kafka Documentation*. 2026. Acesso em: 6 out. 2026. Disponível em: <https://kafka.apache.org/documentation>.

BESU. *Besu Documentation*. 2026. Acesso em: 5 out. 2026. Disponível em: <https://docs.besu-eth.org>.

BISWAS, S.; CHOWDHURY, S.; CHANDRA, S. A cloud-edge based multivariate, real time in-vehicle pollution monitoring system to support a greener environment. *Remote Sensing Applications: Society and Environment*, Elsevier, p. 102035, 2026.

FARRAG, O. et al. Ivemps: Iot-based vehicle emission monitoring and prediction system. *IEEE Access*, IEEE, v. 13, p. 95628–95646, 2025.

KAGAWADE, S. S. et al. Harnessing edge ai for real-time telematics: A framework for low-latency vehicle data analytics. In: *Artificial Intelligence for Transportation*. Boca Raton: CRC Press, 2026. p. 169–188.

KU, D. et al. Vehicle-to-everything-car edge cloud management with development, security, and operations automation framework. *Electronics*, MDPI, v. 14, n. 3, p. 478, 2025.

LIU, X. et al. Lcaa: Lightweight conditional anonymous authentication scheme for vehicular carbon emissions environment. *IEEE Internet of Things Journal*, IEEE, v. 11, n. 19, p. 32025–32040, 2024.

LU, Y. et al. Stricts: A blockchain-enabled smart emission cap restrictive and carbon permit trading system. *Applied Energy*, Elsevier, v. 313, p. 118787, 2022.

LU, Z.; WANG, J. Review on soft sensing of complex industrial processes: Advances, opportunities, and challenges. *Measurement*, Elsevier, p. 123088, 2026.

MEDEIROS, M. et al. A multi-layered methodology for driver behavior analysis using tinyml and edge computing. In: *2024 IEEE International Conference on Evolving and Adaptive Intelligent Systems*. Madrid, Spain: IEEE, 2024. p. 1–8.

MEDEIROS, M.; SILVA, M.; SILVA, I. Evolving online clustering for real-time driver behavior analysis in iot-enabled vehicles. *Evolving Systems*, Springer, v. 16, n. 4, p. 118, 2025.

MICHAILIDIS, E. T.; PANAGIOTOPOULOU, A.; PAPADAKIS, A. A review of obd-ii-based machine learning applications for sustainable, efficient, secure, and safe vehicle driving. *Sensors*, MDPI, v. 25, n. 13, p. 4057, 2025.

NILSSON, A. et al. The autospada platform: User-friendly edge computing for distributed learning and data analytics in connected vehicles. *Internet of Things*, Elsevier, v. 30, p. 101480, 2025.

NODE-RED. *Node-RED Documentation*. 2026. Acesso em: 6 out. 2026. Disponível em: <https://nodered.org/docs/>.

RYKAŁA, M.; GRZELAK, M.; BORUCKA, A. Analysis of the impact of selected dynamic parameters of a motor vehicle on co2 emissions using logistic regression. *Applied Sciences*, MDPI, v. 14, n. 22, p. 10349, 2024.

TYAGI, A. K.; TIWARI, S.; NAITHANI, K. Blockchain-enabled internet of things (iots) platforms for vehicle sensing and transportation monitoring. *Digital Twin and Blockchain for Smart Cities*, Wiley Online Library, p. 257–276, 2024.

ZENDRON, L. A. S. et al. Enhancing human activity recognition with machine learning: insights from smartphone accelerometer and magnetometer data. *PeerJ Computer Science*, PeerJ Inc., v. 11, p. e3137, 2025.

ZHANG, C. et al. Integrating cfd-based digital twins into an iot platform for enhanced greenhouse temperature spatial distribution monitoring. *Internet of Things*, Elsevier, p. 102064, 2026.